

Elementos de Programación Diferenciable

Una Introducción Moderna al Deep Learning

Alejandro Sánchez Yalí

Math & Code Community

9 de abril de 2026

Índice general

1. Mecanismos de atención	1
1.1. El flujo de información en la redes neuronales	1
Apéndice: Material Complementario	3
.1. Demostraciones Adicionales	3
.2. Tablas de Datos	3

Índice de figuras

Índice de cuadros

Capítulo 1

Mecanismos de atención

La capacidad de seleccionar información relevante de un conjunto de datos es un aspecto fundamental de los sistemas inteligentes, ya sean biológicos o artificiales. Por ejemplo, cuando leemos un texto, no prestamos la misma atención a cada palabra, por lo general nos enfocamos en las ideas principales y pasamos por alto detalles menos importantes. Este proceso de selección de información relevante se conoce como atención y ha transformado la forma en que diseñamos y entrenamos las redes neuronales. Las arquitecturas tradicionales como las redes neuronales recurrentes (RNN) y las long short-term memory (LSTM) procesan la información de manera secuencial mientras mantiene un estado interno que se actualiza a medida que se procesan los datos. Sin embargo, estas arquitecturas pueden tener dificultades para capturar dependencias a largo plazo en los datos, por su limitada capacidad de memoria. La atención, por otro lado, permite a las redes neuronales enfocarse en partes específicas de la entrada, lo que facilita la captura de relaciones a largo plazo y mejora el rendimiento en tareas como la traducción automática, el reconocimiento de voz y la generación de texto.

La **atención** es un mecanismo que permite a las redes neuronales asignar diferentes pesos a diferentes partes de la entrada, lo que le permite a la red enfocarse en las partes más relevantes de la información.

1.1 El flujo de información en las redes neuronales

Consideremos una secuencia de entrada $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ que se procesa para producir una secuencia de salida $\mathbf{y} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n)$. En las arquitecturas recurrentes, la información fluye secuencialmente:

$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t) \quad (1.1)$$

donde $\mathbf{h}_t$ es el estado oculto en el tiempo t y f es una función aprendida por la red. El estado oculto $\mathbf{h}_t$ contiene información sobre la secuencia procesada hasta el tiempo t . Esta dependencia secuencial introduce varios desafíos:

1. **Desvanecimiento del gradiente:** A medida que la secuencia se hace más larga, el gradiente que se propaga hacia atrás a través del tiempo puede volverse muy

pequeño, lo que dificulta el aprendizaje de dependencias a largo plazo.

2. **Capacidad de memoria limitada:** La dimensionalidad fija del estado oculto $\mathbf{h}_t$ limita la cantidad de información que la red puede almacenar y procesar a lo largo de la secuencia.
3. **Procesamiento secuencial:** El procesamiento secuencial no permite aprovechar la paralelización, lo que puede ser ineficiente para secuencias largas.
4. **Dificultad para capturar relaciones a largo plazo:** Las dependencias a largo plazo pueden ser difíciles de capturar debido a la naturaleza secuencial del procesamiento.

Apéndice: Material Complementario

.1 Demostraciones Adicionales

Aquí puedes incluir demostraciones más detalladas o extensas que no encajan en el cuerpo principal del libro.

.2 Tablas de Datos

Aquí puedes incluir tablas de datos extensas o información de referencia.