

Elementos de Programación Diferenciable

Una Introducción Moderna al Deep Learning

Alejandro Sánchez Yalí

Math & Code Community

9 de abril de 2026

Índice general

1. Mecanismos de atención en redes neuronales	1
1.1. El paradigma de la atención	1
1.1.1. El flujo de información en la redes neuronales	1
Apéndice: Material Complementario	3
.1. Demostraciones Adicionales	3
.2. Tablas de Datos	3

Índice de figuras

Índice de cuadros

Capítulo 1

Mecanismos de atención en redes neuronales

1.1 El paradigma de la atención

La capacidad de seleccionar información relevante de un conjunto de datos es un aspecto fundamental de los sistemas inteligentes, ya sean biológicos o artificiales. Por ejemplo, cuando leemos un texto, no prestamos la misma atención a cada palabra, por lo general nos enfocamos en las ideas principales y pasamos por alto detalles menos importantes. Este proceso de selección de información relevante se conoce como atención y ha transformado la forma en que diseñamos y entrenamos las redes neuronales. Las arquitecturas tradicionales como las redes neuronales recurrentes (RNN) y las long short-term memory (LSTM) procesan la información de manera secuencial mientras mantiene un estado interno que se actualiza a medida que se procesan los datos. Sin embargo, estas arquitecturas pueden tener dificultades para capturar dependencias a largo plazo en los datos, por su limitada capacidad de memoria. La atención, por otro lado, permite a las redes neuronales enfocarse en partes específicas de la entrada, lo que facilita la captura de relaciones a largo plazo y mejora el rendimiento en tareas como la traducción automática, el reconocimiento de voz y la generación de texto.

La **atención** es un mecanismo que permite a las redes neuronales asignar diferentes pesos a diferentes partes de la entrada, lo que le permite a la red enfocarse en las partes más relevantes de la información.

1.1.1. El flujo de información en las redes neuronales

Consideremos una secuencia de entrada $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ que se procesa para producir una secuencia de salida $\mathbf{y} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n)$. En las arquitecturas recurrentes, la información fluye secuencialmente:

$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t) \tag{1.1}$$

donde $\mathbf{h}_t$ es el estado oculto en el tiempo t y f es una función aprendida por la red. El estado oculto $\mathbf{h}_t$ contiene información sobre la secuencia procesada hasta el tiempo t . Esta

dependencia secuencial introduce varios desafíos:

1. **Desvanecimiento del gradiente:** A medida que la secuencia se hace más larga, el gradiente que se propaga hacia atrás a través del tiempo puede volverse muy pequeño, lo que dificulta el aprendizaje de dependencias a largo plazo.
2. **Capacidad de memoria limitada:** La dimensionalidad fija del estado oculto $\mathbf{h}_t$ limita la cantidad de información que la red puede almacenar y procesar a lo largo de la secuencia.
3. **Procesamiento secuencial:** El procesamiento secuencial no permite aprovechar la paralelización, lo que puede ser ineficiente para secuencias largas.
4. **Dificultad para capturar relaciones a largo plazo:** Las dependencias a largo plazo pueden ser difíciles de capturar debido a la naturaleza secuencial del procesamiento.

Apéndice: Material Complementario

.1 Demostraciones Adicionales

Aquí puedes incluir demostraciones más detalladas o extensas que no encajan en el cuerpo principal del libro.

.2 Tablas de Datos

Aquí puedes incluir tablas de datos extensas o información de referencia.