

Elementos de Programación Diferenciable

Una Introducción Moderna al Deep Learning

Alejandro Sánchez Yalí

Math & Code Community

11 de abril de 2026

Índice general

1. Mecanismos de atención	1
1.1. El flujo de información en la redes neuronales	1
1.2. El mecanismo de atención	2
Apéndice: Material Complementario	3
.1. Demostraciones Adicionales	3
.2. Tablas de Datos	3

Índice de figuras

Índice de cuadros

Capítulo 1

Mecanismos de atención

La capacidad de seleccionar información relevante de un conjunto de datos es un aspecto fundamental de los sistemas inteligentes, ya sean biológicos o artificiales. Por ejemplo, cuando leemos un texto, no prestamos la misma atención a cada palabra, por lo general nos enfocamos en las ideas principales y pasamos por alto detalles menos importantes. Este proceso de selección de información relevante se conoce como atención y ha transformado la forma en que diseñamos y entrenamos las redes neuronales. Las arquitecturas tradicionales como las redes neuronales recurrentes (RNN) y las long short-term memory (LSTM) procesan la información de manera secuencial mientras mantiene un estado interno que se actualiza a medida que se procesan los datos. Sin embargo, estas arquitecturas pueden tener dificultades para capturar dependencias a largo plazo en los datos, por su limitada capacidad de memoria. La atención, por otro lado, permite a las redes neuronales enfocarse en partes específicas de la entrada, lo que facilita la captura de relaciones a largo plazo y mejora el rendimiento en tareas como la traducción automática, el reconocimiento de voz y la generación de texto.

La **atención** es un mecanismo que permite a las redes neuronales asignar diferentes pesos a diferentes partes de la entrada, lo que le permite a la red enfocarse en las partes más relevantes de la información.

1.1 El flujo de información en las redes neuronales

Consideremos una secuencia de entrada $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ que se procesa para producir una secuencia de salida $\mathbf{y} = (\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n)$. En las arquitecturas recurrentes, la información fluye secuencialmente:

$$\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t) \quad (1.1)$$

donde $\mathbf{h}_t$ es el estado oculto en el tiempo t y f es una función aprendida por la red. El estado oculto $\mathbf{h}_t$ contiene información sobre la secuencia procesada hasta el tiempo t . Esta dependencia secuencial introduce varios desafíos:

1. **Desvanecimiento del gradiente:** A medida que la secuencia se hace más larga, el gradiente que se propaga hacia atrás a través del tiempo puede volverse muy

pequeño, lo que dificulta el aprendizaje de dependencias a largo plazo.

2. **Capacidad de memoria limitada:** La dimensionalidad fija del estado oculto $\mathbf{h}_t$ limita la cantidad de información que la red puede almacenar y procesar a lo largo de la secuencia.
3. **Procesamiento secuencial:** El procesamiento secuencial no permite aprovechar la paralelización, lo que puede ser ineficiente para secuencias largas.
4. **Dificultad para capturar relaciones a largo plazo:** Las dependencias a largo plazo pueden ser difíciles de capturar debido a la naturaleza secuencial del procesamiento.

Los mecanismos de atención abordan estas limitaciones a través de un enfoque diferente en el flujo de información. En lugar del procesamiento secuencial, la atención permite que cada elemento de la secuencia de salida $\mathbf{y}_t$ se construya a partir de una combinación ponderada de todos los elementos de la secuencia de entrada $\mathbf{x}$. Esto se logra mediante la asignación de **pesos de atención** que indican la relevancia de cada elemento de la entrada para la generación de la salida en el tiempo t . De esta manera, la atención permite a la red enfocarse en las partes más relevantes de la información, lo que facilita la captura de relaciones a largo plazo y mejora el rendimiento en tareas complejas.

1.2 El mecanismo de atención

El mecanismo de atención computa una representación contentualizada para cada posición tomando el peso promedio de las representaciones de todas las posiciones. Los pesos son determinados por las funciones de aprendizaje compatibles que miden la relevancia entre las posiciones.

Para cada posición i atendiendo a todas las posiciones $j = 1, \dots, n$, la atención se calcula como:

$$e_{ij} = \text{score}(\mathbf{q}_i, \mathbf{k}_j) \quad (1.2)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^n \exp(e_{ik})} \quad (1.3)$$

$$\mathbf{c}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j \quad (1.4)$$

donde $\mathbf{q}_i$ es la consulta (query) para la posición i , $\mathbf{k}_j$ es la clave (key) que representa que información que se encuentra en la posición j , y $\mathbf{v}_j$ es el valor (value) que contiene la información actual para ser utilizada en la generación de la salida. Los pesos de atención α_{ij} forman una distribución de probabilidad sobre las posiciones de la entrada, lo que permite determinar cuánta atención se debe prestar a cada posición para generar la salida en la posición i . Esta formulación provee varias ventajas:

1. **Acceso directo a la información relevante:** La posición i puede acceder directamente a cualquier posición j de la entrada, con el peso de atención α_{ij} controlando el flujo de la información.

Apéndice: Material Complementario

.1 Demostraciones Adicionales

Aquí puedes incluir demostraciones más detalladas o extensas que no encajan en el cuerpo principal del libro.

.2 Tablas de Datos

Aquí puedes incluir tablas de datos extensas o información de referencia.